

基本扩展模块/网络爬虫

陈斌 北京大学 gischen@pku.edu.cn

网络爬虫

- > 搜索引擎蜘蛛
- > requests库
- > Beautiful Soup
- **爬虫的基本流程**

搜索引擎蜘蛛

〉 爬虫是按照一定规则,自动地提取并保存网 页中信息的程序

蜘蛛沿着网络抓取猎物

通过一个节点之后,顺着该节点的连线继续爬行到下一个节点,最终爬完整个网络的全部节点

通过向网站发起请求获取资源,提取其中有

用的信息



- > Python实现的一个简单易用的HTTP库
 - 支持HTTP持久连接和连接池、SSL证书验证、cookies处理、流式上传等
- 〉 向服务器发起请求并获取响应,完成访问网 页的步骤
- > 简洁、容易理解,是最友好的网络爬虫库

〉 http请求类型

```
requests.request():构造一个请求requests.get():获取HTML网页requests.head():获取HTML网页头信息requests.post():提交POST请求requests.put():提交PUT请求requests.patch():提交局部修改请求requests.delete():提交删除请求requests.options():获取http请求
```

> 返回的是一个response对象

› response对象

包含服务器返回的所有信息,例如状态码、编码形式、文本内容等;也包含请求的request信息

.status_code: HTTP请求的返回状态

.text: HTTP响应内容的字符串形式

.content: HTTP响应内容的二进制形式

.encoding: (从HTTP header中)分析响应内容的

编码方式

.apparent_encoding: (从内容中)分析响应内容

的编码方式

```
>>> import requests
>>> r = requests.get("http://www.baidu.com")
>>> r.status code
200
>>> r.text
'<!DOCTYPE html>\r\n<!--STATUS OK--><html> <head><meta http-equiv=content-type content=tex
t/html;charset=utf-8><meta http-equiv=X-UA-Compatible content=IE=Edge><meta content=always
name=referrer><link rel=stylesheet type=text/css href=http://sl.bdstatic.com/r/www/cache/b
dorz/baidu.min.css><title>c\x99%å°;ä,\x80ä,\x8bï4\x8cä4\xa0å°±c\x9f¥é\x81\x93</title></hea
>>> r.encoding
'ISO-8859-1'
>>> r.apparent encoding
'utf-8'
>>> r.encoding = "utf-8"
>>> r.text
'<!DOCTYPE html>\r\n<!--STATUS OK--><html> <head><meta http-equiv=content-type content=tex
t/html;charset=utf-8><meta http-equiv=X-UA-Compatible content=IE=Edge><meta content=always
name=referrer><link rel=stylesheet type=text/css href=http://sl.bdstatic.com/r/www/cache/b
dorz/baidu.min.css><title>百度一下, 你就知道</title></head> <body link=#0000cc> <div id=wrap
```

〉定制请求头

requests的请求接口有一个名为headers的参数, 向它传递一个字典来完成请求头定制

〉设置代理

一些网站设置了同一IP访问次数的限制,可以在发送请求时指定proxies参数来替换代理,解决这一问题

Beautiful Soup

〉页面解析器

使用requests库下载了网页并转换成字符串后,需要一个解析器来处理HTML和XML,解析页面格式,提取有用的信息

> 解析器类型

解析器	使用方法	优势
python标准库	BeautifulSoup(markup, "html.parser")	- Python的内置标准库 - 文档容错能力强
lxml HTML解析器	BeautifulSoup(markup, "lxml")	- 速度快 - 文档容错能力强
lxml XML解析器	BeautifulSoup(markup, ["lxml-xml"]) BeautifulSoup(markup, "xml")	- 速度快 - 唯一支持XML的解析器
Html5lib	BeautifulSoup(markup, "html5lib")	- 最好的容错性 - 以浏览器的方式解析文档 - 生成HTML5格式的文档



Beautiful Soup

〉搜索方法

```
find_all(name, attrs, recursive, string,
**kwargs)
返回文档中符合条件的所有tag,是一个列表
find(name, attrs, recursive, string,
**kwargs)
相当于find_all()中limit = 1, 返回一个结果
name: 对标签名称的检索字符串
attrs:对标签属性值的检索字符串
recursive: 是否对子节点全部检索, 默认为True
string: <>...</>> 中检索字符串
**kwargs: 关键词参数列表
```


爬虫的基本流程



爬虫的基本流程

〉爬取页面

通过requests库向目标站点发送请求,若对方服务器正常响应,能够收到一个response对象,它包含了服务器返回的所有信息



爬虫的基本流程

〉解析页面

- HTML代码-网页解析器
- Json数据-json模块,转换成Json对象
- 二进制数据-以wb形式写入文件,再做进一步处理 此处使用bs4进行解析

```
Python 3.6.2 Shell
File Edit Shell Debug Options Window Help
                                                        from bs4 import BeautifulSoup
标题: 数据透视中美贸易摩擦: 最新清单的分析
链接: https://news.qq.com/a/20180719/000993.htm
                                                         soup = BeautifulSoup(r.text, 'lxml')
标题: 国际镜评: 日本歐盟抱团擔自贸 这是造美国的反?
链接: https://new.gg.com/om/ST02018071900109600
                                                         for news in soup.find all('div', class = 'text'):
                                                               info = news.find('a')
标题:未来房价能否平稳、肉价会大涨? 多部门权威回应
链接: https://new.gq.com/omn/20180719/20180719A027P800
                                                               if len(info) > 0:
标题: 教育部: 参与购买、代写学位论文将开除学籍
链接: https://news.qq.com/a/20180719/001325.htm
                                                                       title = info.get text()
标题: 北京监狱管理局: 李天一仍在服刑,未减刑或假释链接: http://ent.qq.com/a/20180718/040549.htm
                                                                       link = str(info.get('href'))
                                                                       print('标题: ' + title)
标题: 瓜农喝止小偷被杀凶犯获死刑 其子: 要工作撑起家链接: https://new.qq.com/20180719/20180719A00E1M00
                                                                        print('链接: ' + link + '\n')
标题: 巴西众院弹劾总统案箓通过 罗塞夫政党承认落败
链接: http://news.qq.com/a/20160418/023091.htm
标题: 国际锐评: 日本和歐盟抱团擔自贸 这是要造美国的反?
链接: http://new.qq.com/cmsn/20180719/20180719001096.html
标题:中国科技公司迎来最疯狂上市潮,小米之后美团拼多多蓄势待发链接: http://new.qq.com/omn/20180716/20180716A1CB3H.html
```

标题: 新京报评论: 央行与财政部专家争鸣,有莫大公共价值 链接: http://new.qq.com/tt/template/?id=FIM2018071702306600 标题: 北京监狱管理局: 李天一仍在服刑,并未取刑或解释 链接: http://new.qq.com/cnsm/20180718/20180718040549.html 标题: 大公司要闻速览 | 谷歌遭欧盟43亿欧元重罚: 阿里150亿投分众链接: http://new.qq.com/cnsm/20180718/TEC2018071803887600